

NEWYORKDRIVE

**NATALIA QUEJIA
CARLOS HADLA
JAIR ALARCON
ISMAEL FLORES**

**ANÁLISIS DE PROPUESTA DE IMPLEMENTACIÓN DE FLOTA ELÉCTRICA EN LA
CIUDAD DE NEW YORK**

**HENRY BOOTCAMP COHORTE 16 DATA SCIENCE
ARGENTINA, COLOMBIA
2023**

ÍNDICE

RESUMEN EJECUTIVO.....	2
PROBLEMÁTICA.....	3
INTRODUCCIÓN.....	3
EQUIPO DE TRABAJO.....	3
METODOLOGÍA DE TRABAJO.....	3
OBJETIVO GENERAL.....	4
ALCANCE.....	4
STACK TECNOLÓGICO.....	4
VIDA DEL DATO.....	6
KPIs.....	8
MODELADO DE MACHINE LEARNING.....	10
CONCLUSIÓN.....	11

RESUMEN EJECUTIVO

Este proyecto representa un paso significativo hacia la transformación del sistema de transporte, al buscar implementar una solución más sostenible y eficiente. Se ha llevado a cabo un análisis exhaustivo respaldado por un equipo multidisciplinario con un enfoque colaborativo y una metodología ágil.

El proyecto comenzó identificando la problemática: la necesidad de expandir el servicio de transporte de pasajeros hacia vehículos más sostenibles. La introducción planteó la visión de la empresa de alinearse con tendencias de mercado y prácticas sostenibles. El equipo de trabajo, conformado por expertos en datos, ingeniería y aprendizaje automático, se ha centrado en la selección y uso de tecnologías adecuadas para abordar esta problemática.

La metodología de trabajo, basada en Scrum y respaldada por herramientas colaborativas como Trello, ha permitido una gestión eficiente del proyecto. Esta metodología ha proporcionado una estructura flexible y adaptable, permitiendo la iteración y el enfoque en entregas incrementales.

El alcance del proyecto abarca desde la obtención de datos hasta la implementación de soluciones basadas en análisis profundos. Se ha empleado un stack tecnológico robusto, incluyendo Google Colab, Python y Google Cloud Platform (GCP), que han servido como pilares para la adquisición, limpieza, análisis y almacenamiento de datos de alta calidad.

La vida del dato ha sido fundamental, desde la obtención a través de técnicas como web scraping y acceso a APIs, hasta el Análisis Exploratorio detallado para comprender la estructura y la calidad de los datos. La automatización de procesos mediante Cloud Functions y Cloud Scheduler ha asegurado una gestión eficiente y organizada de datos en BigQuery, sentando así las bases para futuros análisis y modelos de Machine Learning.

Este proyecto representa un esfuerzo integral para desarrollar un sistema de transporte más sostenible y eficiente. El enfoque colaborativo, la cuidadosa gestión de datos, el análisis profundo y la definición de KPIs nos han guiado hacia una toma de decisiones informada y estratégica en pos de un futuro más sostenible en el transporte de pasajeros.

PROBLEMÁTICA

Una empresa de transporte de pasajeros, actualmente enfocada en micros de media y larga distancia, busca expandirse al sector de transporte de pasajeros con automóviles. Con una visión de futuro sostenible y alineada con las tendencias de mercado, la empresa desea evaluar la relación entre los vehículos particulares y la calidad del aire, así como la contaminación sonora. El objetivo es estudiar la viabilidad de incorporar vehículos eléctricos a su flota, ya sea en su totalidad o en parte.

INTRODUCCIÓN

La empresa "NewYorkDrive" ha solicitado a nuestro equipo; realizar un estudio para respaldar su proceso de toma de decisiones, respecto a la implementación de una nueva línea de transporte. El enfoque principal es garantizar que esta nueva línea sea rentable, eficiente y respetuosa con el medio ambiente. Se llevará a cabo una investigación exhaustiva utilizando datos de alta calidad de fuentes clave en la ciudad de Nueva York para analizar las características fundamentales que influyen en la toma de decisiones.

EQUIPO DE TRABAJO

Carlos Hadla: Data Engineer

Natalia Queija: Data Analytic

Jair Alarcón: Machine Learning

Ismael Flores: Especialista en GCP

METODOLOGÍA DE TRABAJO

En este proyecto, adoptaremos la metodología ágil Scrum como marco de trabajo principal, respaldado por la plataforma colaborativa Trello para la gestión y seguimiento de las tareas. Scrum nos permitirá abordar las complejidades del proyecto mediante iteraciones cortas y entregas incrementales, enfocándonos en la flexibilidad, adaptación constante y colaboración entre los equipos. Utilizaremos Trello como una herramienta visual para organizar, priorizar y monitorear el progreso de las tareas en tiempo real, asegurando una comunicación fluida y una visión clara del avance del proyecto para todo el equipo.

OBJETIVO GENERAL

Dado que esta unidad de negocio sería nueva, se busca realizar un análisis preliminar del movimiento de taxis en la ciudad de Nueva York. El objetivo es establecer un marco de referencia que permita tomar decisiones informadas durante el proceso de implementación de la nueva línea de transporte.

ALCANCE

En respuesta a la problemática global del cambio climático, que afecta a todas las poblaciones, la empresa "NewYorkDrive" tiene la intención de introducir una flota de vehículos eléctricos en la ciudad de Nueva York. Este proyecto considerará aspectos clave como energías alternativas, impacto ambiental y rentabilidad. Se enfocará especialmente en la viabilidad, cumpliendo con los acuerdos establecidos por la ciudad para el cambio tecnológico en el transporte, con el objetivo de reducir la huella de carbono y generar un impacto positivo en la comunidad a corto y mediano plazo.

STACK TECNOLÓGICO

- **Google Colab:**

Justificación: Google Colab proporciona un entorno de desarrollo de Python en la nube basado en Jupyter Notebooks, que permite colaborar en tiempo real en la escritura y ejecución de código Python. Al ser parte de Google Drive, facilita el acceso a conjuntos de datos almacenados en la nube y ofrece recursos de hardware como GPU y TPU de forma gratuita, lo que es especialmente útil para ejecutar modelos de Machine Learning que requieren potencia computacional adicional. Además, su integración con otros servicios de Google Cloud Platform simplifica la carga y el procesamiento de datos directamente desde Colab a otras herramientas como BigQuery o Cloud Storage. Esta herramienta es valiosa para la investigación, desarrollo y prototipado rápido de algoritmos antes de implementarlos en un entorno de producción en GCP.

- **Python:**

Justificación: Python es un lenguaje de programación versátil y poderoso para el análisis de datos. Su gran cantidad de bibliotecas (como Pandas, NumPy, Matplotlib) y su facilidad para manejar datos lo convierten en una opción excelente para manipular y analizar conjuntos de datos complejos.

- **Google Cloud Platform (GCP):**

Justificación: GCP proporciona una infraestructura escalable y confiable para alojar aplicaciones y servicios en la nube. Ofrece una variedad de herramientas para el

almacenamiento, procesamiento y análisis de datos, lo que facilita el manejo de grandes volúmenes de información de forma eficiente y segura.

- **Cloud Function:**

Justificación: Las Cloud Functions permiten ejecutar código de manera automatizada en respuesta a eventos en la nube sin preocuparse por la administración de servidores. Esto es útil para realizar tareas específicas en el flujo de trabajo del análisis de datos, como procesamiento por lotes o acciones automatizadas.

- **Google Cloud Scheduler:**

Justificación: Google Cloud Scheduler permite programar y automatizar tareas en GCP, ejecutando servicios de manera periódica o según horarios específicos. Es útil para la programación de trabajos de procesamiento de datos, activación de flujos de trabajo y gestión de tareas recurrentes en la nube.

- **Google Cloud Storage:**

Justificación: Google Cloud Storage proporciona un almacenamiento escalable y duradero en la nube. Permite almacenar grandes cantidades de datos de forma segura y acceder a ellos de manera eficiente. Es ideal para el almacenamiento de datos de análisis, archivos de respaldo, contenido multimedia y conjuntos de datos estructurados o no estructurados.

- **BigQuery:**

Justificación: BigQuery es un servicio de almacenamiento y análisis de datos completamente administrado que permite consultar grandes conjuntos de datos de manera rápida y eficiente. Su escalabilidad y capacidad para manejar grandes volúmenes de datos lo hacen ideal para realizar consultas y análisis complejos.

- **Power BI:**

Justificación: Power BI es una herramienta de visualización de datos que permite crear informes interactivos y paneles dinámicos. Al integrarse con otros servicios de datos como BigQuery, facilita la creación de visualizaciones efectivas para presentar y comunicar los resultados del análisis.

- **Vertex AI:**

Justificación: Vertex AI es una plataforma de Machine Learning completamente administrada que permite el desarrollo, entrenamiento y despliegue de modelos de manera eficiente. Su integración con otras herramientas de GCP simplifica el proceso de implementación de modelos de aprendizaje automático en la infraestructura de la nube.

VIDA DEL DATO

Obtención del dato:

- El proceso de adquisición de datos se llevó a cabo a partir de diversas fuentes para recopilar información clave. Se emplearon técnicas de web scraping desde el portal oficial del gobierno de la ciudad de Nueva York para extraer datos relacionados con los taxis amarillos, verdes y servicios de transporte de aplicaciones como Uber, Lyft, entre otros. Además, se obtuvo un dataset consolidado que abarcaba los promedios mensuales de estos datos desde el año 2013 hasta la actualidad.
- Además de la obtención de datos mediante web scraping, se utilizó el acceso a APIs para obtener información valiosa. Esto incluyó datos sobre la contaminación a lo largo de varios años, así como detalles específicos sobre los tipos de vehículos y su nivel de emisión en distintas circunstancias, ya sea por milla recorrida, por hora, etc. Otro dataset obtenido a través de API fue el relacionado con los 'medallion', que contiene información detallada sobre las acreditaciones de taxis en Nueva York.

EDA (Análisis Exploratorio de Datos):

- Cada dataset se sometió a un análisis minucioso. Se llevó a cabo una revisión exhaustiva de cada conjunto de datos para entender su estructura, la calidad de la información, la presencia de valores atípicos o nulos, así como para determinar qué variables eran relevantes para los objetivos del proyecto. Para facilitar este proceso, se creó un diccionario detallado para cada dataset, documentando todas las variables y sus características, lo que permitió tomar decisiones informadas sobre qué datos retener y cómo manejarlos en las siguientes etapas del proceso.

Automatización:

- Una de las piezas clave en este proyecto fue la automatización del flujo de datos. Esto se logró utilizando las herramientas de Google Cloud Platform (GCP) para establecer un sistema automatizado robusto. Se programaron cronogramas en GCP que activaban disparadores (triggers) en Cloud Functions para descargar datos desde las diferentes fuentes. Estos datos se almacenan inicialmente en Google Cloud Storage (GCS). Posteriormente, se implementó un segundo disparador en Cloud Function para iniciar la limpieza de los datos recién descargados. Esta limpieza incluyó la eliminación de datos redundantes, la corrección de datos incorrectos o faltantes, y la agrupación según las decisiones tomadas durante la exploración de datos previa.
- El proceso de limpieza dejó los datos listos y preparados para su carga en BigQuery de GCP. Los archivos limpios se almacenaron en un nuevo bucket de GCS en espera de ser agregados a las tablas de BigQuery, preparadas y estructuradas para recibir esta información.

Data Warehouse:

- La transferencia de datos a BigQuery se llevó a cabo utilizando DataTransfer, también configurado en GCP. Este proceso se ejecutó minutos después de que se

completaran todas las operaciones de limpieza y preparación de datos en GCS. Una vez que los datos se transfirieron a BigQuery, se organizaron en sus tablas correspondientes.

- Posteriormente, se realizaron actualizaciones en los diccionarios de datos para reflejar las nuevas tablas y la estructura en BigQuery. Esto facilitó enormemente la implementación de técnicas de machine learning, ya que se contaba con un marco de datos bien definido y organizado. Además, se sentó la base para la construcción de un dashboard interactivo que permitiría visualizar los datos actualizados mes a mes en tiempo real.
- Este enfoque meticuloso y automatizado no solo garantizó la adquisición de datos de múltiples fuentes, sino que también permitió su limpieza y organización eficientes. La estructura establecida en BigQuery y la actualización constante de los datos sentaron las bases para futuros análisis, implementaciones de machine learning y presentaciones visuales para la toma de decisiones fundamentadas.

Machine Learning:

- Creación de un modelo de regresión lineal para obtener las tarifas, gastos en combustibles y gastos en kw, con el fin de obtener una utilidad del servicio basado en millas recorridas y flota empleada, también tuvimos en cuenta gastos como mantenimiento y ganancia del conductor.
- Se intentó la implementación en GCP a través de vertex ia utilizando un modelo de regresión lineal con autoML, pero debido a las limitaciones de la versión gratuita no pudimos avanzar con este desarrollo. Pero realizamos la creación del modelo de forma local e implementamos el modelo para tener una mejor visualización del modelo.

Dashboard:

- Diseño y desarrollo de un dashboard interactivo que presenta de manera clara y concisa la información derivada del análisis de datos.
- Se realizaron 5 hojas:
 - “Estadísticas”, donde se visualizan las estadísticas generales del negocio de los últimos 10 años
 - “ROI”, en donde se analiza el retorno de la inversión de forma comparativa entre los autos a combustión y los autos eléctricos. Para ambos casos, se predijeron las ganancias netas con el modelo de Machine Learning y se calcularon los costos de inversión y combustible según los datos obtenidos.
 - “Eficiencia en Rutas”, gracias a distintos gráficos se evalúan los tiempo promedio de los viajes, las distancias recorridas, y analizar como podríamos mejorar la eficiencia de las rutas gracias a distintas aplicaciones.
 - “Costos de Combustible”, se analiza la diferencia en los costos de carga de un auto a combustible a diferencia de los autos eléctricos. Reflejando claramente una disminución en los costos de combustible si pasamos la flota a eléctricos.
 - “Reducción de emisiones”, donde analizamos tanto los gases emitidos por los autos tanto como la contaminación sonora en la ciudad.

KPIs

Estos son los KPIs que estaremos desarrollando a lo largo del proyecto, esto con fines de realizar un seguimiento mensual y anual con diversos datos para llegar a conclusiones más concretas y confiables.

1. Retorno de inversión (ROI) esperado por la implementación de la flota de vehículos eléctricos:

El ROI se calcula teniendo en cuenta el beneficio neto obtenido por la inversión dividido por el costo de la inversión, expresado como un porcentaje.

$$\text{ROI} = \frac{\text{Beneficio Neto}}{\text{Costo de la Inversión}} \times 100$$

Podemos decir, por ejemplo, que el retorno esperado por la implementación de vehículos eléctricos va a ser de un 20% luego del período de 6 años.

También hacer lo mismo para vehículos a combustión interna para hacer una comparativa.

2. Reducción de emisión de carbono:

La Reducción de Emisiones (%) es un indicador clave de rendimiento que evalúa la efectividad de las medidas adoptadas para reducir las emisiones generadas por los vehículos de combustión. La fórmula es la siguiente:

$$\text{Reducción de Emisiones} = \frac{\text{Reducción de Emisiones}}{\text{Emisiones de Vehículos de Combustión}} \times 100$$

Al 50% anual

3. KPI de Eficiencia de Rutas:

Nos enfocamos en evaluar la eficiencia de las rutas de los taxis, con el objetivo de optimizar la distancia promedio recorrida por cada viaje.

$$\text{Distancia promedio por viaje} = \frac{\text{Sumatoria de todas las distancias recorridas en viajes}}{\text{Número total de viajes}}$$

Podemos decir que buscamos reducir la distancia promedio por viaje en un 10% en los próximos seis meses, implementando estrategias de optimización de rutas y proporcionando orientación a los conductores para mejorar la eficiencia del servicio.

4. Calidad del aire en zonas de servicio

Relación entre la calidad del aire y la cantidad de viajes en diferentes zonas.

Revelar si existe alguna relación entre la cantidad de viajes de taxis en una zona específica y los niveles de contaminación del aire en esa área. Puede medirse en periodos de tiempo mensuales/ anuales.

Calidad del aire en zonas de servicio	=	$\frac{\text{Nivel de contaminación Anterior} - \text{Nivel contaminación Actual}}{\text{Nivel de contaminación Anterior}} \times 100$
---	---	--

Reducción del nivel de contaminación del aire en una zona específica

Se mediría la disminución porcentual en los niveles de contaminantes en comparación con un punto de referencia previo.

5. Eficiencia en Costos de Combustible

La Eficiencia en Costos de Combustible es un indicador clave que evalúa el ahorro económico derivado de la utilización de vehículos eléctricos en comparación con los vehículos de combustión en términos de costos operativos. La fórmula para calcular este KPI es la siguiente:

Eficiencia en costo de combustible	=	$\frac{\text{Costos operativos promedio por vehículo eléctrico} - \text{Costos operativos promedio por vehículo de combustión}}{\text{Costos operativos promedio por vehículo eléctrico}} \times 100$
--	---	---

MODELADO DE MACHINE LEARNING

Para desarrollar el modelo de machine learning, se llevó a cabo un minucioso análisis de los datos almacenados en el almacén de datos. La primera etapa consistió en un estudio exhaustivo de la información proveniente de diversas tablas y fuentes. El objetivo primordial fue integrar datos coherentes y fiables, evitando así la inclusión de información que pudiera afectar la precisión o capacidad predictiva del modelo.

En una segunda instancia, se abordó la normalización de variables, considerando especialmente aquellas que podrían beneficiar modelos lineales. Además, se tuvo en cuenta la correlación entre variables y se excluyeron datos correspondientes a periodos problemáticos, como los años afectados por la pandemia del coronavirus, para mantener la integridad del modelo.

Como tercera medida, se procedió con el modelado local utilizando el enfoque de regresión lineal, una elección respaldada por los análisis previos. Este modelo fue entrenado y evaluado, y los resultados iniciales fueron altamente satisfactorios, gracias a la aplicación de hiperparámetros óptimos.

La variable principal para la búsqueda del modelo fue la distancia, la cual influyó directamente en las predicciones de la huella de carbono y la utilidad en flotas de taxis con motores de combustión y eléctricos. Los resultados obtenidos demostraron ser altamente eficientes.

En una cuarta fase, se procedió a subir el modelo para pruebas en la plataforma GCP mediante la API de VERTEX. Sin embargo, se encontraron dificultades técnicas al utilizar funciones de AUTOML a través de un notebook interactivo con Jupyter lab y el SDK de Python. A pesar de intentar simplificar y modificar los datos, los problemas persistieron. La búsqueda de soluciones incluyó el cambio de fuentes de datos y la habilitación de todos los permisos posibles en la plataforma, sin éxito. Finalmente, se identificó que la limitación estaba relacionada con las cuotas, donde el modelo requería un mínimo de 60 cuotas, mientras que la plataforma gratuita solo permitía hasta 45 cuotas. Ante esta restricción, se solicitó un aumento de cuotas, pero se informó que esta opción solo estaba disponible en modalidad de pago.

Ante la limitación de cuotas, surgió la alternativa de implementar una herramienta de despliegue utilizando la plataforma FastAPI. Con la aplicación funcionando, se consideró mostrar los resultados en Power BI, completando así la presentación analítica.

CONCLUSIÓN

Luego de un exhaustivo análisis del negocio llegamos a las siguientes conclusiones, divididas entre las ventajas y los desafíos o contrapartidas:

Ventajas:

1. Retorno de Inversión (ROI):

- La implementación de una flota de taxis eléctricos en Nueva York muestra un retorno de inversión promedio de dos años en adelante. Este corto período refleja la eficiencia económica de migrar a vehículos eléctricos.

2. Mejor Zona para Operar:

- Manhattan se destaca como la mejor zona para operar una flota de taxis eléctricos, probablemente debido a su densidad poblacional y características geográficas que favorecen el uso eficiente de vehículos eléctricos.

3. Incentivos Tributarios:

- La ciudad está ofreciendo beneficios tributarios para facilitar la transición de flotas de combustión a eléctricas, promoviendo la adopción de tecnologías más sostenibles.

4. Eficiencia en Rutas:

- Se destaca que la eficiencia de las rutas se mide más en tiempo que en distancia, indicando que los taxis eléctricos son capaces de navegar eficientemente por la ciudad.

5. Infraestructura de Carga:

- Nueva York cuenta con una amplia capacidad de estaciones de carga eléctrica a un precio competitivo, facilitando la recarga de la flota de taxis eléctricos.

6. Reducción de Contaminantes:

- La adopción de taxis eléctricos contribuye significativamente a la reducción de contaminantes, tanto en emisiones directas como en la contaminación sonora, mejorando la calidad del aire y la salud pública.

7. Impacto Ambiental:

- La principal contaminación asociada con la flota eléctrica es indirecta, relacionada con la fabricación de vehículos y la sostenibilidad de las estaciones de carga.

Desafíos y Contrapartidas:

1. Costos Iniciales Elevados:

- Aunque el ROI es atractivo a largo plazo, la inversión inicial en la transición a una flota eléctrica puede resultar considerablemente alta.

2. Limitaciones de Autonomía:

- Aunque la infraestructura de carga es robusta, la autonomía limitada de algunos vehículos eléctricos podría ser un desafío en un entorno de alta demanda y tráfico denso.

3. Impacto Ambiental de la Fabricación:

- A pesar de que la operación de la flota eléctrica es limpia, la fabricación de vehículos eléctricos todavía conlleva una carga ambiental significativa.

4. Dependencia de Estaciones de Carga:

- La eficiencia de la flota eléctrica depende de la disponibilidad y funcionalidad de las estaciones de carga. Problemas en la infraestructura podrían afectar la operatividad de la flota.

5. Desafíos de Sostenibilidad:

- La contaminación indirecta asociada con la fabricación de vehículos y la sostenibilidad de las estaciones de carga plantean interrogantes sobre la verdadera huella ecológica de la transición.

En resumen, la transición a una flota de taxis eléctricos en Nueva York presenta ventajas económicas y ambientales significativas, respaldadas por incentivos gubernamentales y una infraestructura de carga en crecimiento. Sin embargo, existen desafíos relacionados con costos iniciales, autonomía limitada y la sostenibilidad completa de la cadena de suministro de vehículos eléctricos. La toma de decisiones debe considerar cuidadosamente estos factores para garantizar una transición exitosa y sostenible hacia tecnologías más limpias y eficientes.